

RELATÓRIO — OUVIDORIA INTELIGENTE

Tendências em Ciências da Computação

Instituição: UNIPÊ Professor: Me. Ricardo Roberto de Lima

Equipe: Gabriel Xavier, Patrick Sardenbeg, Kevyn Cassiano

1. Objetivo

O projeto implementa um protótipo de triagem semântica de manifestações cidadãos. A solução compara representações esparsas (BoW e TF-IDF) com embeddings densos, calcula similaridade de cosseno, detecta possíveis duplicatas, aplica chunking a textos longos e disponibiliza uma interface interativa em Streamlit.

2. Arquitetura e decisões

BoW e TF-IDF foram implementados com scikit-learn. Para embeddings, foram disponibilizados dois modelos sentence-transformers, permitindo comparar uma alternativa multilíngue com uma alternativa voltada ao português. O app utiliza cache para evitar recarregamento desnecessário do modelo e dos embeddings.

3. Busca semântica

A consulta do cidadão é transformada em embedding e comparada aos embeddings das manifestações por similaridade de cosseno. O sistema ordena os resultados e apresenta os cinco primeiros por padrão, com classificação visual: verde para score acima de 0,7, amarelo acima de 0,5 e vermelho nos demais casos.

4. Detecção de duplicatas

A função `detectar_duplicatas` percorre os pares de manifestações e retorna aqueles cuja similaridade excede 0,85. O valor é tratado como limiar inicial, e não como uma verdade universal: a calibração deve considerar o modelo e o corpus. A matriz completa é apresentada em heatmap no notebook.

5. Chunking

Para textos longos é utilizada a estratégia `RecursiveCharacterTextSplitter`. Foram previstas duas configurações de tamanho e sobreposição. O overlap mantém parte do contexto entre chunks consecutivos, podendo melhorar a coesão nas fronteiras, embora também aumente a redundância e o custo de processamento.

6. Visualização

PCA e t-SNE são utilizados para projetar os embeddings em duas dimensões. A visualização permite observar relações entre manifestações e verificar, de maneira exploratória, se as categorias oficiais apresentam separação no espaço semântico.

7. Interface

O Streamlit possui quatro áreas: Busca Semântica, Base Completa, Espaço Vetorial e Chunking. A barra lateral permite selecionar o modelo de embedding e o número de resultados.

8. Limitações e dificuldades

A principal limitação é que os resultados de similaridade dependem do modelo escolhido e do corpus. O limiar de duplicatas pode gerar falsos positivos ou falsos negativos e deve ser validado com anotações reais. PCA e t-SNE são projeções para visualização e não substituem métricas quantitativas. O dataset incluído neste pacote é demonstrativo porque o enunciado recebido não continha o JSON oficial.

9. Aprendizados

O desenvolvimento evidencia a diferença entre correspondência lexical e representação semântica. Embeddings tornam possível recuperar manifestações parafraseadas mesmo quando as palavras não coincidem exatamente. Chunking permite trabalhar textos longos sem tratar todo o conteúdo como um único bloco.

Conclusão: o protótipo atende à estrutura funcional solicitada no desafio e pode ser executado localmente no VS Code. Para a entrega acadêmica final, recomenda-se substituir o dataset demonstrativo pelo arquivo oficial e executar os notebooks para gerar os valores e gráficos correspondentes aos dados reais.